

UNIVERSIDADE DO VALE DO RIO DOS SINOS (UNISINOS)

UNIDADE ACADÊMICA DE GRADUAÇÃO

CURSO DE ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO RAFAEL DE BORBA

APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL PARA NEGÓCIOS.

Criando indicadores para tomada de decisões.

MONTENEGRO

2025

BRUNO RAFAEL DE BORBA

APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL PARA NEGÓCIOS.

Criando indicadores para tomada de decisões.

Artigo apresentado como requisito para obtenção do título de Tecnólogo em Análise e Desenvolvimento de Sistemas, pelo Curso de Análise e Desenvolvimento de Sistemas da Universidade do Vale do Rio dos Sinos (UNISINOS).

Orientador(a): Prof. Dr. Roberto Zanoni

MONTENEGRO

2025

APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NO MUNDO DOS NEGÓCIOS.

Criando indicadores para tomada de decisões.

BRUNO RAFAEL DE BORBA

RESUMO

Este artigo aborda a aplicação de Inteligência Artificial (IA) em um provedor de internet e canais digitais do setor de telecomunicações, onde o desafio é manter os clientes na base, aumentando a fidelidade e reduzindo o Churn Rate (cancelamento de serviços). A IA, através de modelos de Machine Learning (ML), hoje em dia se tornou muito utilizada na transformação digital das empresas, permitindo prever o comportamento dos clientes e tomar melhores decisões. O foco deste projeto é utilizar modelos preditivos para identificar clientes com alto risco de Churn, classificando esse risco em alto, moderado ou baixo, baseando-se em dados.

Palavras-chave: inteligência artificial; aprendizado de máquina; telecomunicações; churn; previsão de churn; retenção de clientes.

ABSTRACT

This article addresses the application of Artificial Intelligence (AI) in an internet and digital channels provider in the telecommunications sector, where the challenge is to retain customers, increasing loyalty and reducing the churn rate (service cancellation). AI, through Machine Learning (ML) models, has become widely used in the digital transformation of companies, enabling the prediction of customer behavior and better decision-making. The focus of this project is to use predictive models to identify customers at high risk of churn, classifying this risk as high, moderate or low based on data.

Keywords: artificial intelligence; machine learning; telecommunications; churn; churn prediction; customer retention.

SUMÁRIO

1 INTRODUÇÃO.....	4
1.1 Justificativa	5
1.2 Objetivos.....	5
1.2.1 Objetivo Geral.....	5
1.2.2 Objetivos Específicos	6
1.2.3 Questão de Pesquisa	6
2 REFERENCIAL TEÓRICO	6
2.1 Inteligência Artificial e Machine Learning	6
2.2 Previsão de Churn.....	7
2.3 Aplicações de Machine Learning em Telecomunicações	7
2.4 Modelos	8
2.5 Desafios e Oportunidades	8
2.6 Trabalhos Relacionados	8
3 METODOLOGIA DE PESQUISA	10
3.1 Caracterização da Pesquisa	10
3.2 Etapas da Pesquisa.....	11
3.2.1 Identificação do Problema	11
3.2.2 Definição dos Objetivos da Solução	11
3.2.3 Desenvolvimento da Aplicação	11
a) Coleta de Dados	12
b) Pré-processamento de Dados	13
c) Análise Exploratória.....	13
d) Implementação de Modelos de ML	13
3.2.4 Demonstração da Aplicação.....	14
3.2.5 Avaliação	14
3.2.6 Comunicação dos Resultados	14
3.3 Considerações Finais da Metodologia	14

4 DESENVOLVIMENTO	15
4.1 Coleta de dados	16
4.2 Pré-Processamento de Dados	16
4.3 Análise Exploratória	20
4.4 Implementação de Modelos	21
4.5 Implementação do Modelo Escolhido	22
4.6 Instrumentos de Coleta de Dados	25
5 RESULTADOS E DISCUSSÃO	26
5.1 Predições Individuais	26
5.2 Indicadores Globais de Desempenho	26
5.3 Representações Gráficas por Subgrupos	27
5.4 Discussão dos Resultados	29
REFERÊNCIAS	31

1 INTRODUÇÃO

A retenção de clientes é um dos principais desafios enfrentados por empresas do setor de telecomunicações, dado o elevado nível de concorrência e a facilidade de migração entre provedores. Nesse cenário, o Churn Rate (Taxa de cancelamento de serviços) torna-se um indicador estratégico de desempenho organizacional.

A Inteligência Artificial (IA), por meio de técnicas de Machine Learning (ML), surge como ferramenta eficaz para antecipar comportamentos e apoiar decisões gerenciais. A partir da análise preditiva, é possível identificar clientes com maior risco ao cancelamento e propor ações preventivas.

Este estudo propõe o desenvolvimento e a aplicação de modelos de classificação supervisionada para prever o risco de churn em uma base de clientes de telecomunicações. O entregável, construído sob a ótica do Design Science Research (DSR), utiliza a linguagem Python e a biblioteca scikit-learn, reconhecida por sua eficiência na implementação de algoritmos de aprendizado de máquina.

1.1 Justificativa

A aplicação de técnicas de Machine Learning (ML) na previsão de churn justifica-se pela necessidade das empresas em antecipar comportamentos e adotar ações preventivas baseadas em dados. A análise de informações históricas permite identificar padrões, contribuindo para decisões mais assertivas.

O uso da Inteligência Artificial (IA) oferece ainda uma vantagem competitiva, ao permitir maior agilidade, precisão e eficácia na gestão de clientes em mercados altamente dinâmicos (NGUYEN; MUTUM, 2012).

Entre os principais benefícios esperados destacam-se:

- Aumento da retenção de clientes;
- Redução de perdas financeiras;
- Melhoria da experiência do cliente;
- Fortalecimento da competitividade organizacional.

1.2 Objetivos

1.2.1 Objetivo Geral

Aplicar e avaliar modelos de Machine Learning supervisionado (classificação) capazes de prever o risco de evasão de clientes (churn), com base em dados históricos, de modo a gerar indicadores que contribuam para a melhoria de estratégias de retenção e tomada de decisão.

1.2.2 Objetivos Específicos

- Analisar conjuntos de dados históricos relacionados à evasão de clientes, identificando variáveis e padrões comportamentais;
- Selecionar e implementar diferentes algoritmos de Machine Learning, como Random Forest e Redes Neurais Artificiais, com foco na previsão de churn;
- Avaliar e comparar o desempenho dos modelos utilizando métricas, tais como acurácia, precisão e recall;
- Identificar os principais fatores que contribuem para o churn;
- Classificar o risco de churn dos clientes em categorias de baixo, médio e alto risco.

1.2.3 Questão de Pesquisa

De que forma a aplicação de modelos de classificação supervisionada em Machine Learning pode contribuir para prever e reduzir a evasão de clientes nos negócios, aumentando a retenção?

2 REFERENCIAL TEÓRICO

2.1 Inteligência Artificial e Machine Learning

A Inteligência Artificial (IA) é o campo da computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam

raciocínio humano, como reconhecimento de padrões e tomada de decisão (RUSSELL; NORVIG, 2010).

Dentro desse escopo, o Machine Learning (ML) destaca-se como subárea da IA voltada à criação de algoritmos que aprendem com dados e aprimoram seu desempenho com o tempo, sem necessidade de programação explícita (MITCHELL, 1997). Essas técnicas têm se consolidado como base da análise preditiva moderna, permitindo a automação de decisões e a descoberta de padrões.

2.2 Previsão de Churn

O churn representa a taxa de evasão de clientes em determinado período e constitui um importante indicador de desempenho. A previsão do churn permite antecipar comportamentos e adotar estratégias de retenção orientadas por dados (BLATTBERG et al., 2008).

Entre os principais algoritmos aplicados a essa finalidade estão:

- Árvores de Decisão, que classificam registros com base em regras lógicas (QUINLAN, 1986);
- Floresta Randômica, que combina múltiplas árvores para elevar a precisão (BREIMAN, 2001);
- Redes Neurais Artificiais, capazes de captar relações não lineares (LECUN et al., 2015).

A eficácia dos modelos é mensurada por métricas como acurácia, precisão, recall e F1-score, que indicam o equilíbrio entre acertos e erros de classificação (FAWCETT, 2006).

2.3 Aplicações de Machine Learning em Telecomunicações

A aplicação de modelos preditivos baseados em ML tem se mostrado altamente eficaz no setor de telecomunicações, permitindo a identificação de clientes com risco de cancelamento e o direcionamento de ações preventivas personalizadas (NGUYEN; MUTUM, 2012). Além de prever o risco, estes modelos revelam fatores importantes para o churn, como insatisfação com atendimento, falhas de serviço e

políticas de preços, apoiando decisões e aprimorando a experiência do cliente (CHEN et al., 2012).

2.4 Modelos

Dentre os modelos mais utilizados na previsão de churn, destacam-se:

- Artificial Neural Network (ANN), compostas por camadas de neurônios artificiais que ajustam pesos com base no erro de previsão, por meio do algoritmo *backpropagation* (MCCULLOCH; PITTS, 1943; RUMELHART; HINTON; WILLIAMS, 1986);
- Random Forest (RF), algoritmo baseado em um conjunto de múltiplas árvores de decisão que operam de forma agregada. Essa abordagem reduz a variância individual de cada árvore e aumenta a precisão e estabilidade das previsões, sendo amplamente utilizada em problemas de classificação e previsão de churn (BREIMAN, 2001).
- Support Vector Machines (SVM), que determinam o hiperplano ótimo de separação entre classes e apresentam excelente desempenho em problemas binários (CORTES; VAPNIK, 1995).

2.5 Desafios e Oportunidades

A aplicação de ML em cenários reais envolve desafios como qualidade dos dados, tratamento de bases desbalanceadas e interpretação dos resultados por usuários não técnicos. No entanto, quando bem implementadas, essas técnicas proporcionam ganhos em fidelização de clientes, personalização de ofertas e rentabilidade (KELLEHER et al., 2015).

2.6 Trabalhos Relacionados

Diversos estudos vêm sendo desenvolvidos com o objetivo de aplicar técnicas de Machine Learning na previsão de evasão de clientes (*churn*), visando oferecer suporte à tomada de decisão nas empresas.

Um exemplo prático é o trabalho intitulado “Aplicação de Churn Prediction com Machine Learning”, publicado por André Almeida na plataforma Medium, em 30 de dezembro de 2022. Neste estudo, o autor explora o conceito de *Churn Rate*, abordando desde sua definição até as etapas de análise exploratória e modelagem preditiva.

Foram utilizadas bibliotecas em Python voltadas à análise de dados, como Dython (para correlações entre variáveis categóricas) e Boxplot (para visualização gráfica dos dados). A base de dados foi dividida em conjuntos de treino e teste, sendo aplicada validação cruzada para assegurar robustez ao modelo.

Os algoritmos de aprendizado de máquina empregados incluíram:

- Support Vector Machines (SVM): usado para classificação, encontrando o hiperplano que melhor separa as classes;
- Random Forest: método baseado em múltiplas árvores de decisão com votação majoritária;
- XGBoost: técnica de *Gradient Boosting* que corrige erros iterativamente a cada árvore gerada.

Além disso, foram aplicadas técnicas de balanceamento de dados, como Random Under-Sampling e SMOTE, e busca por hiperparâmetros com Grid Search CV, resultando em uma acurácia de 77% na classificação de clientes com risco de evasão.

Outro trabalho relevante é o artigo publicado na revista *Expert Systems with Applications*, o qual discute estratégias avançadas para melhorar a performance de modelos de previsão de churn em contextos com desequilíbrio de classes. Os autores destacam o uso de técnicas de ensemble learning, que combinam diferentes modelos para aumentar a acurácia preditiva.

Segundo James et al. (2013), *"a melhoria da precisão preditiva é essencial para que os modelos de Machine Learning ofereçam previsões mais confiáveis e úteis, permitindo que empresas identifiquem com maior eficiência os clientes propensos ao cancelamento de serviços, aumentando assim as ações de retenção e a receita."*

Quadro 1 – Comparativo entre trabalhos relacionados sobre previsão de churn

Critério	Almeida (2022, Medium)	Expert Systems with Applications (JAMES et al., 2013)
Objetivo	Aplicação prática de ML para prever churn	Proposta de boas práticas e melhoria de acurácia preditiva
Fonte	Publicação informal (Medium)	Artigo científico revisado por pares
Técnicas de Modelagem	SVM, Random Forest, XGBoost	Ensemble Learning
Balanceamento de Dados	SMOTE, Random Under-Sampling	Técnicas especializadas para desequilíbrio de classes
Ferramentas Utilizadas	Python, Dython, Grid Search CV	Não especificado
Resultado/Acurácia	77% de acerto	Acurácia superior com técnicas avançadas de ensemble
Contribuição Principal	Demonstração prática com boas práticas	Discussão técnica sobre aumento de desempenho preditivo

Fonte: Elaborado pelo autor (2025).

3 METODOLOGIA DE PESQUISA

A presente pesquisa adota como orientação metodológica o Design Science Research (DSR), uma abordagem estruturada voltada à construção e avaliação de aplicações computacionais que solucionem problemas práticos, ao mesmo tempo em que contribuem para o conhecimento científico (HEVNER et al., 2004). No contexto deste trabalho, o entregável consiste na aplicação de modelos preditivos de Machine Learning (ML) voltados à previsão da evasão de clientes (*churn*) no setor de telecomunicações.

O DSR se mostra adequado por permitir a integração entre rigor científico e prática, guiando o desenvolvimento de soluções baseadas em dados, focando na geração de indicadores que auxiliem a tomada de decisão.

A estrutura metodológica segue as fases tradicionais do DSR: identificação do problema, definição de objetivos da solução, desenvolvimento da aplicação demonstração, avaliação e comunicação dos resultados.

3.1 Caracterização da Pesquisa

Os objetivos deste estudo podem ser classificados como exploratórios e descritivos:

- Exploratória, por buscar identificar padrões e variáveis e padrões nos dados históricos de clientes;
- Descritiva, por analisar e apresentar o comportamento dos clientes e os fatores associados à sua evasão.

A abordagem metodológica é quantitativa, com base em análise de dados estruturados, aplicando algoritmos de classificação supervisionada. O estudo é aplicado, pois visa à resolução de um problema real com relevância organizacional e potencial impacto no negócio.

3.2 Etapas da Pesquisa

3.2.1 Identificação do Problema

A perda de clientes impacta negativamente a receita e eleva os custos operacionais, uma vez que a aquisição de novos consumidores tende a ser mais onerosa do que sua retenção. O objetivo é antecipar os casos de churn por meio de modelos preditivos.

3.2.2 Definição dos Objetivos da Solução

O objetivo é desenvolver uma aplicação de algoritmos, capaz de prever, com precisão, a propensão de um cliente cancelar os serviços. A solução visa classificar clientes em risco alto, moderado ou baixo e para os que forem classificados como alto e moderado, apoiar em estratégias.

3.2.3 Desenvolvimento da Aplicação

a) Coleta de Dados

Os dados utilizados foram extraídos da plataforma Kaggle, representando uma base simulada de clientes de uma empresa de telecomunicações.

A base analisada contém 4020 registros representando clientes de uma empresa de telecomunicações, estruturada em formato tabular, com 13 variáveis entre atributos demográficos, comportamentais e de consumo, sendo a variável-alvo *Exited*, que indica se o cliente cancelou (1) ou permaneceu (0) com o serviço.

As colunas consistem em:

- *CustomerID*: ID único atribuído ao cliente.
- *Surname*: Sobrenome do cliente.
- *NetworkScore*: Pontuação de qualidade da rede para o cliente (quanto maior, melhor).
- *Region*: Região do cliente.
- *Gender*: Gênero do cliente.
- *Age*: Idade do cliente.
- *Tenure*: Número de anos que o cliente está com a empresa.
- *MonthlyCharge*: Cobrança mensal para o cliente.
- *NumOfProducts*: Número de produtos de telecomunicações que o cliente está usando.
- *HasInternetService*: Se o cliente tem serviço de internet (1 = Sim, 0 = Não).
- *IsActiveMember*: Se o cliente é um membro ativo (1 = Sim, 0 = Não).
- *EstimatedMonthlyUsage*: Uso mensal estimado do cliente.
- *Exited*: Se o cliente deixou a empresa ou não (1 = Sim, 0 = Não).

Fonte: Kaggle. *Telecom Customer Churn Analysis and Prediction*. Disponível em: <https://www.kaggle.com>

Algumas variáveis apresentam valores ausentes:

- NetworkScore: 199 valores ausentes (~4,95%)
- Age: 208 ausentes (~5,17%)
- IsActiveMember: 198 ausentes (~4,93%)
- EstimatedMonthlyUsage: 197 ausentes (~4,90%)

As demais variáveis estão completas, a seguir, são destacados os principais indicadores estatísticos:

- Idade dos Clientes (Age): média de 43,96 anos, com desvio padrão de 15,3 variando entre 18 e 70 anos.
- Tempo de Contrato (Tenure): média de 10 anos, com variação entre 0 e 20 anos.
- Cobrança Mensal (MonthlyCharge): valor médio de R\$ 109,81, variando entre R\$ 20,03 e R\$ 199,96.
- Região (Region): 4 regiões presentes, sendo North a mais representativa (1023 clientes).
- Gênero (Gender): distribuição entre Masculino (~33%), Feminino (~33%) e Outro (em menor proporção).
- Serviço de Internet (HasInternetService): levemente balanceado – 50,7% dos clientes têm serviço de internet.
- Cancelamento (Exited): taxa de evasão de 48,6%, o que indica uma alta rotatividade da base.

b) Pré-processamento de Dados

Inclui as seguintes etapas:

- Tratamento de valores ausentes e anômalos;
- Codificação de variáveis categóricas;
- Normalização de dados contínuos.

c) Análise Exploratória

Técnicas estatísticas e de visualização gráfica para compreensão dos dados, distribuição das variáveis e identificação de padrões iniciais.

d) Implementação de Modelos de ML

Implementação e comparação dos seguintes algoritmos:

- Random Forest (RF)
- Artificial Neural Network (ANN)

A base de dados é dividida em conjuntos de treino e teste, utilizando validação cruzada para garantir maior completude na avaliação. Dessa forma, garantindo que todos os dados sejam submetidos a balanceamentos, análises e testes.

3.2.4 Demonstração da Aplicação

Aplicação realizada sobre o conjunto de dados de teste, com o objetivo de simular seu uso prático em um ambiente real, gerando indicadores de risco de churn para cada cliente, permitindo avaliar o desempenho preditivo dos modelos.

3.2.5 Avaliação

Eficácia dos modelos avaliada com base em métricas de desempenho como:

- Acurácia
- Precisão
- Recall
- F1-Score

Essas métricas permitem comparar a capacidade de generalização dos algoritmos, possibilitando a escolha do modelo mais adequado ao cenário.

3.2.6 Comunicação dos Resultados

A partir dos resultados obtidos, possibilita a criação de indicadores gerenciais e recomendações, com o objetivo de orientar a retenção de clientes. O conhecimento adquirido é útil tanto para a academia quanto para o setor empresarial, demonstrando como soluções baseadas em IA podem ser aplicadas de forma prática para geração de valor.

3.3 Considerações Finais da Metodologia

A aplicação do Design Science Research proporciona uma abordagem sistemática e iterativa, garantindo que todas as etapas desde a coleta de dados até a avaliação dos modelos sejam conduzidas aos objetivos do projeto.

Ao transformar dados em insights, a aplicação desenvolvida possibilita à empresa não apenas prever comportamentos, mas também agir de forma proativa, otimizando seus recursos e melhorando o relacionamento com os clientes.

4 DESENVOLVIMENTO

A etapa de desenvolvimento corresponde à aplicação prática da metodologia Design Science Research (DSR), voltada à construção e avaliação de um modelo preditivo de evasão de clientes (churn).

As atividades foram conduzidas em Python, linguagem muito utilizada em ciência de dados pela flexibilidade e pela variedade de bibliotecas especializadas.

Entre as principais ferramentas empregadas destacam-se:

- Pandas e NumPy: manipulação e estruturação dos dados;
- Matplotlib e Seaborn: análise exploratória e visualização gráfica;
- Scikit-learn: implementação dos algoritmos de *Machine Learning*, validação cruzada e cálculo das métricas de desempenho.

Foram aplicadas técnicas de estatística descritiva, análise de correlação, tratamento de valores ausentes e detecção de outliers, assegurando a integridade da base. Para o preparo dos dados, utilizaram-se métodos de padronização (StandardScaler) e balanceamento (SMOTE), essenciais para o desempenho dos modelos supervisionados.

O desenvolvimento foi organizado em quatro fases principais:

1. Coleta de dados;
2. Pré-processamento;
3. Análise exploratória;
4. Implementação e validação dos modelos.

Cada etapa é descrita a seguir, apresentando as fases adotadas, os resultados obtidos e as evidências que sustentam a eficácia do modelo proposto.

4.1 Coleta de dados

A coleta de dados representa a primeira etapa do desenvolvimento, responsável por fundamentar a construção de soluções baseadas em evidências.

Os dados utilizados foram obtidos da plataforma Kaggle, no repositório Public Telecom Customer Churn Analysis and Prediction. A escolha dessa base justifica-se por sua estrutura consistente, bastante utilizada em pesquisas acadêmicas e competições de ciência de dados, simulando condições reais do setor de telecomunicações.

A base é pública e fictícia, garantindo reprodutibilidade e conformidade ética, e está disponível em formato .csv, o que facilita a leitura e manipulação em Python. Contém 4.020 registros na base de treino e 1.980 na base de teste, totalizando 5.940 clientes fictícios, distribuídos em 13 variáveis independentes e uma variável-alvo (Exited), que indica se o cliente cancelou (1) ou permaneceu (0) no serviço.

As variáveis englobam dados demográficos (idade, gênero, região), comportamentais (tempo de vínculo, uso mensal, status de membro ativo) e financeiros (cobrança mensal, número de produtos contratados). Essa diversidade permite ao modelo identificar padrões para prever o churn.

Por fim, os dados foram divididos entre conjunto de treino e conjunto de teste, assegurando a independência na etapa de validação do modelo preditivo.

4.2 Pré-Processamento de Dados

O pré-processamento de dados representa uma parte importante no ciclo, garantindo a qualidade da base a ser utilizada pelos algoritmos. Dados brutos frequentemente contêm valores ausentes, redundâncias ou variações, que podem comprometer o resultado dos modelos, caso não sejam tratados.

No presente estudo, o pré-processamento foi conduzido em diferentes fases complementares:

a) Tratamento de valores ausentes:

Conforme identificado na etapa de coleta, algumas variáveis contêm registros incompletos, como *NetworkScore*, *Age*, *IsActiveMember* e *EstimatedMonthlyUsage*. Para lidar com essas inconsistências, aplicou-se técnicas de **imputação estatística**, preservando a integridade da base, populando valores faltantes com a média. A figura 1 apresenta esses dados incompletos e a figura 2, apresenta o resultado após correção.

Figura 1 – Soma de Valores Nulos por Variável

```
# Check
customer_data.isnull().sum()

CustomerID      0
Surname         0
NetworkScore    199
Region          0
Gender          0
Age            208
Tenure          0
MonthlyCharge   0
NumOfProducts   0
HasInternetService 0
IsActiveMember  198
EstimatedMonthlyUsage 197
Exited          0
dtype: int64
```

Fonte: Elaborado pelo autor (2025).

Figura 2 – Soma de Valores Nulos Após Correção em Python

```
# Check
customer_data.isnull().sum()

CustomerID      0
Surname         0
NetworkScore    0
Region          0
Gender          0
Age            0
Tenure         0
MonthlyCharge   0
NumOfProducts  0
HasInternetService 0
IsActiveMember 0
EstimatedMonthlyUsage 0
Exited          0
dtype: int64
```

Fonte: Elaborado pelo autor (2025).

b) Codificação de variáveis categóricas:

A presença de variáveis como *Region* e *Gender* demandou a aplicação de técnicas de codificação (*encoding*) para que pudesse ser processado pelos algoritmos. Foi adotada a abordagem de *Encoding*, que converte categorias em variáveis binárias, evitando a introdução de relações inexistentes entre categorias. A figura 3 apresenta os dados categóricos em formato de tabela, a figura 4 apresenta os dados após transformação para binário.

Figura 3 – Valores Categóricos

	Surname	Region	Gender
0	Moreno	South	Female
1	Bell	North	Female
2	Baker	North	Male
3	Jackson	South	Male
4	Craig	East	Female
...	...	...	...
4015	Deleon	North	Other
4016	Yang	North	Other
4017	Mckenzie	South	Female
4018	Smith	North	Male
4019	Lopez	East	Male

Fonte: Elaborado pelo autor (2025).

Figura 4 – Valores Categóricos Transformados em Binário

	0	2	3
0	561	2	0
1	54	1	0
2	30	1	1
3	406	2	1
4	186	0	0
...	...	...	...
4015	209	1	2
4016	865	1	2
4017	523	2	0
4018	751	1	1
4019	472	0	1

Fonte: Elaborado pelo autor (2025).

c) Normalização e padronização dos dados:

Após transformar os valores categóricos em binários, aplicou-se as técnicas nomeadas SMOTE e Standard Scale, que tem como finalidade, distribuir o peso de forma linear entre variáveis para que se tornem equilibradas entre si. Este resultado é exibido na figura 5.

Figura 5 - Aplicação de SMOTE e Scale para Equilíbrio de Variáveis

```
array([[ 0.42878225, -0.93083012,  0.46013562, ..., -1.02186982,
        0.98087814,  0.00224068],
       [-1.5944814 ,  0.59587584, -0.43985418, ...,  0.98766013,
        0.98087814, -0.05733645],
       [-1.69025719, -0.61128701, -0.43985418, ..., -1.02186982,
       -1.02930049, -0.15265986],
       ...,
       [ 0.62215863,  0.39988833,  0.07119778, ...,  0.98766013,
        0.98087814,  1.70281336],
       [ 0.37291304, -0.94274672, -1.06501961, ...,  0.98766013,
        0.98087814,  0.00224068],
       [-0.43911443,  0.03086389, -0.90279655, ...,  0.98766013,
       -1.02930049,  1.06964264]], shape=(4136, 11))
```

Fonte: Elaborado pelo autor (2025).


4.3 Análise Exploratória

A etapa de análise exploratória dos dados (Exploratory Data Analysis – EDA) tem como objetivo compreender o conjunto de informações coletadas, identificando padrões, tendências, distribuições e potenciais inconsistências que possam influenciar o desempenho dos modelos.

A análise iniciou-se com a avaliação da qualidade dos dados, considerando a presença de valores ausentes. Foi realizada a contabilização de registros nulos em cada variável, identificando lacunas em atributos como *NetworkScore*, *Age*, *IsActiveMember* e *EstimatedMonthlyUsage*. Para uma melhor interpretação, elaborou-se imagens, representando a quantidade de valores ausentes por variável, o que possibilitou uma visualização clara das inconsistências e reforçou a necessidade do processo de imputação.

A variável-alvo *Exited* (indicadora de churn) revelou uma taxa de evasão próxima a 48,6%, demonstrando um equilíbrio entre clientes que permaneceram e os que cancelaram os serviços. Esse balanceamento é favorável à construção de modelos de classificação, uma vez que reduz a necessidade de técnicas complexas de balanceamento de classes. Esse equilíbrio é representado pela figura 6.

Figura 6 – Valores da classe 'Exited'



Fonte: Elaborado pelo autor (2025).

Além disso identificou-se que os dados estavam muito dispersos entre si, o que demandou uma transformação nos dados para que se tornassem linearmente mais próximos.

4.4 Implementação de Modelos

Nesta etapa, foram aplicados algoritmos supervisionados de classificação com o objetivo de prever o risco de evasão de clientes (*churn*) e comparar o desempenho entre diferentes abordagens.

Foram selecionados dois modelos amplamente utilizados na literatura:

- Random Forest (RF): algoritmo baseado em múltiplas árvores de decisão combinadas por votação majoritária. Essa técnica de *ensemble learning* reduz o risco de *overfitting*, proporciona robustez e permite interpretar a importância das variáveis (BREIMAN, 2001).
- Artificial Neural Network (ANN): inspiradas na estrutura cerebral humana, foram aplicadas para captar relações complexas e não lineares entre os atributos. A arquitetura incluiu camadas densas e funções de ativação não lineares, otimizadas para maximizar a predição.

Os modelos foram implementados em Python, utilizando a biblioteca scikit-learn, e salvos por meio do módulo pickle, que permite a serialização e desserialização dos objetos, possibilitando a reutilização dos modelos treinados sem necessidade de recriação.

Para garantir uma avaliação confiável, aplicou-se validação cruzada ($k = 10$) sobre a base de treinamento, técnica que reduz o viés e avalia a generalização do modelo. O quadro 2, mostra o comparativo entre os modelos aplicados.

Quadro 2 – Comparativo de desempenho dos modelos.

Modelo	Acurácia	Precisão	Recall	F1-Score	Média Kross	Desvio Padrão	Conclusão
Random Forest	0.76	0.72	0.86	0.78	0.75	0.02	Melhor desempenho em recall e acurácia.
ANN	0.74	0.71	0.82	0.76	0.74	0.02	Desempenho estável, porém, inferior em recall e acurácia.

Fonte: Elaborado pelo autor (2025).

Os resultados indicam desempenho semelhante entre os modelos, com leve superioridade do Random Forest, que obteve acurácia média de 75% e melhor equilíbrio entre *precision* e *recall*. Assim, o Random Forest foi escolhido como modelo preditivo principal deste estudo, por aliar bom desempenho e estabilidade.

4.5 Implementação do Modelo Escolhido

Após a seleção, aplicou-se o modelo Random Forest, sobre a base de teste, composta por 1.980 registros, a fim de avaliar sua capacidade. Assim como na etapa de treino, os dados foram submetidos a procedimentos de padronização e balanceamento, garantindo que estivessem adequados para a predição.

Os resultados obtidos, após submeter a base de teste ao modelo treinado, evidenciaram uma taxa de evasão (churn) de 66,67% entre os clientes avaliados, conforme a distribuição da variável *Exited*:

- Exited = 1 (Cancelou): 1320 clientes

- Exited = 0 (Permaneceu): 660 clientes


O resultado da análise revelou comportamentos distintos entre grupos:

- Taxa de churn por região:
 - East: 68,71%
 - South: 66,94%
 - West: 65,97%
 - North: 65,07%
- Taxa de churn por gênero:
 - Female: 99,69%
 - Male: 61,20%
 - Other: 40,69%

Em resumo:

- 66,67% = percentual total de churn da base de teste.

Figura 7 - Distribuição de Clientes




Fonte: Elaborado pelo autor (2025).

- 99,69% (Female) = dentro das mulheres, praticamente todas cancelaram.
- 61,21% (Male) = dentro dos homens, 61% cancelaram.


- 40,69% (Other) = dentro dos "Outros", 40% cancelaram.

Figura 8 – Taxa de Churn por Gênero



Fonte: Elaborado pelo autor (2025).

Figura 9 – Taxa de Churn por Região



Fonte: Elaborado pelo autor (2025).

Esses resultados demonstram que, além de atingir bons indicadores estatísticos, o modelo foi capaz de identificar padrões no comportamento dos clientes, evidenciando maior propensão ao churn entre mulheres e variações regionais.

4.6 Instrumentos de Coleta de Dados

Para a validação do algoritmo desenvolvido, adotou-se a técnica de estudo de caso, sustentada por uma abordagem quantitativa e descritiva. O objetivo foi avaliar, de forma sistemática, o desempenho do modelo preditivo Random Forest aplicado a uma base de clientes de telecomunicações, simulando um ambiente de negócio real.

O estudo foi conduzido em ambiente computacional controlado, utilizando a base de teste composta por 1.980 registros, segregada previamente da base de treino para garantir a independência e imparcialidade da avaliação. A execução do modelo permitiu coletar métricas quantitativas como acurácia, precisão, recall e F1-score, além de análises segmentadas por atributos demográficos (gênero, região) e comportamentais.

A coleta das evidências ocorreu de forma automatizada, abrangendo três frentes principais:

- **Predições individuais:** aplicou-se o método `predict()` da biblioteca *scikit-learn* sobre a base de teste, gerando para cada cliente um rótulo binário (0 = permanece, 1 = churn) e a probabilidade correspondente (*predict_proba*). As predições foram exportadas em formato CSV, garantindo rastreabilidade e reprodutibilidade.
- **Indicadores globais de desempenho:** as métricas foram calculadas com as funções `accuracy_score`, `precision_score`, `recall_score` e `f1_score` exibindo a performance do modelo.
- **Representações gráficas:** para identificar padrões demográficos e comportamentais, aplicou-se o método `groupby` do *pandas*, gerando gráficos de barras e pizza (via *matplotlib* e *seaborn*) que evidenciam as taxas de churn por gênero e região, bem como a distribuição geral dos clientes.

Os dados foram organizados em formato tabular e visual, assegurando transparência e rastreabilidade. A escolha do estudo de caso justifica-se por permitir uma avaliação contextualizada do modelo, fornecendo evidências sobre sua eficácia e aplicabilidade.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados obtidos a partir da aplicação do modelo Random Forest na base de teste (1.980 registros), em concordância com a metodologia descrita no item 4.6. As análises foram conduzidas contemplando previsões individuais, indicadores globais de desempenho e representações gráficas das taxas de churn em subgrupos.

5.1 Previsões Individuais

As previsões individuais foram geradas por meio do método `predict()` da biblioteca *scikit-learn*, retornando para cada cliente um rótulo binário (0 = permaneceu; 1 = churn) e a probabilidade associada (`predict_proba`). Esse procedimento permitiu identificar não apenas se um cliente tem maior propensão ao cancelamento, mas também quantificar o grau de risco de cada registro. Dessa forma, clientes com probabilidades superiores a 0,60 podem ser classificados como de alto risco, enquanto aqueles com valores entre 0,50 e 0,60 representam um grupo de risco moderado, ambos recebendo o rótulo = 1.

Os resultados foram armazenados em formato CSV, contendo o identificador de cada cliente, o rótulo previsto e a respectiva probabilidade, assegurando rastreabilidade e permitindo futuras análises gerenciais ou replicações do estudo.

5.2 Indicadores Globais de Desempenho


A avaliação quantitativa da performance do modelo foi realizada por meio de métricas reconhecidas na literatura de *Machine Learning*. Os resultados estão sintetizados na Tabela 5.1 e Figura 10.

Tabela 5.1 – Métricas de desempenho do modelo Random Forest (base de teste)

Métrica	Valor
Acurácia	0,76
Precisão	0,72
Recall	0,86
F1-Score	0,78

Fonte: Elaborado pelo autor (2025).

Figura 10 - Distribuição de Clientes por Nível de Risco



Fonte: Elaborado pelo autor (2025).

A matriz revelou que o modelo foi eficaz na identificação de clientes que cancelaram, minimizando falsos negativos e elevando o recall (0,86). Esse indicador é relevante em contextos de churn, uma vez que a não identificação de clientes em risco pode resultar em erros para a empresa.

Além disso, a validação cruzada ($k = 10$) apresentou média de 0,75 com desvio padrão de 0,02, confirmando a consistência do modelo em diferentes subconjuntos da base.

5.3 Representações Gráficas por Subgrupos

A análise segmentada buscou identificar padrões de churn entre diferentes perfis de clientes, utilizando técnicas de agregação (*groupby*) e visualizações geradas com *matplotlib* e *seaborn*.

- Distribuição Geral: 66,67% dos clientes da base de teste foram classificados como churn, contra 33,33% que permaneceram.
- Taxa de churn por gênero:
 - Female: 99,69%
 - Male: 61,21%
 - Other: 40,69%
- Taxa de churn por região:
 - East: 68,71%
 - South: 66,94%
 - West: 65,97%
 - North: 65,07%

Observação:

Os dados foram agrupados por *Region* ou *Gender* e utilizou-se `mean()`, dessa forma o Python calcula a média da variável binária (*Exited*) dentro de cada grupo. Exemplo para *Gender*:

- Female: 99,69% cancelaram
- Male: 61,21% cancelaram
- Other: 40,69% cancelaram


Isso não soma 100%, porque não são percentuais de distribuição da base inteira, mas sim a taxa de cancelamento dentro de cada grupo, aplicando-se também para taxa de churn por região.

Os resultados demonstram maior vulnerabilidade ao churn entre clientes do gênero feminino e nas regiões East e South, evidenciando perfis prioritários para estratégias de retenção.

Analisando os grupos de forma geral, os resultados apresentados foram os seguintes:

Figura 10 - Distribuição Percentual de Churn por Gênero


Distribuição Percentual de Churn por Gênero



Fonte: Elaborado pelo autor (2025).

Figura 11 - Distribuição Percentual de Churn por Região

Distribuição Percentual de Churn por Região



Fonte: Elaborado pelo autor (2025).

5.4 Discussão dos Resultados

A análise dos resultados confirma que o Random Forest é um modelo adequado para previsão de churn. Seu desempenho consistente, aliado à capacidade de identificar padrões em diferentes grupos de clientes, o torna um algoritmo aplicável em cenários reais.

Do ponto de vista gerencial, os resultados oferecem subsídios para a empresa, permitindo a implementação de medidas direcionadas a clientes classificados como de alto e médio risco. Entre as soluções possíveis, destacam-se:

- Programas de retenção personalizados, com ofertas específicas para segmentos vulneráveis (ex.: descontos e benefícios adicionais para mulheres e clientes da região East e South).
- Atendimento proativo aos clientes classificados com alta probabilidade de churn, buscando compreender suas insatisfações e propor alternativas.
- Monitoramento contínuo, utilizando o modelo como ferramenta de apoio à tomada de decisão, alimentado periodicamente com novos dados para manter a precisão das predições.

Assim, os resultados obtidos não apenas validam a eficácia do modelo, mas também demonstram seu potencial de aplicação prática como ferramenta de suporte estratégico, alinhando-se aos objetivos estabelecidos neste estudo.

REFERÊNCIAS

- BLATTBERG, R. C.; GETZ, G.; THOMAS, J. S. *Customer Equity: Building and Managing Relationships as Valuable Assets*. Harvard Business Press, 2008.
- BREIMAN, L. *Random Forests*. *Machine Learning*, v. 45, p. 5–32, 2001.
- CHEN, Y. L. et al. *Customer segmentation based on data mining and behavioral scoring model*. *Expert Systems with Applications*, v. 39, n. 3, p. 2234–2243, 2012.
- FAWCETT, T. *An introduction to ROC analysis*. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006.
- JAMES, G. et al. *An empirical comparison of techniques for class imbalance in churn prediction*. *Expert Systems with Applications*, v. 40, n. 11, p. 4313–4320, 2013.
- KELLEHER, J. D.; NAMEE, B. M.; D'ARCY, A. *Fundamentals of Machine Learning for Predictive Data Analytics: Algorithms, Worked Examples, and Case Studies*. MIT Press, 2015.
- LeCUN, Y.; BENGIO, Y.; HINTON, G. *Deep learning*. *Nature*, v. 521, p. 436–444, 2015.
- MCCULLOCH, W. S.; PITTS, W. *A logical calculus of the ideas immanent in nervous activity*. *Bulletin of Mathematical Biophysics*, v. 5, p. 115–133, 1943.
- MITCHELL, T. M. *Machine Learning*. McGraw-Hill, 1997.
- NGUYEN, B.; MUTUM, D. S. *A model for customer churn prediction in the telecom sector*. *Journal of Business Research*, v. 65, n. 11, p. 1574–1581, 2012.
- QUINLAN, J. R. *Induction of decision trees*. *Machine Learning*, v. 1, n. 1, p. 81–106, 1986.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. *Learning representations by back-propagating errors*. *Nature*, v. 323, p. 533–536, 1986.
- RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 3. ed. Pearson Education, 2010.
- HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. *Design Science in Information Systems Research*. *MIS Quarterly*, v. 28, n. 1, p. 75–105, 2004.

- ALMEIDA, A. *Aplicação de Churn Prediction com Machine Learning*. Medium, 2022. Disponível em: <https://medium.com/@andre-almd/aplica%C3%A7%C3%A3o-de-churn-prediction-com-machine-learning-cca6164033ec>. Acesso em: abr. 2025.